

电力市场中基于 Attention-LSTM 的 短期负荷预测模型

彭文, 王金睿, 尹山青

(华北电力大学 控制与计算机工程学院, 北京市 昌平区 102206)

Short-term Load Forecasting Model Based on Attention-LSTM in Electricity Market

PENG Wen, WANG Jinrui, YIN Shanqing

(School of Control and Computer Engineering, North China Electric Power University, Changping District, Beijing 102206, China)

ABSTRACT: In electricity market environment, accurate short-term load forecasting can ensure safe and stable operation of power grid, and save a lot of cost for power generation, electricity sales and power consumption units. However, real-time fluctuations in electricity prices increase complexity of load changes and difficulty of forecasting. In view of such situation, the maximum information coefficient method was used to analyze the correlation of current time load with electricity price and historical load respectively in this paper. The input feature vector of the prediction model could be determined with this method. And on this basis, a short-term load forecasting model based on Attention-LSTM (Attention long short-term memory) network was proposed. The model took full advantage of the timing characteristics of the load and used Attention mechanism to highlight input features playing key role in load forecasting. Taking the real data of a certain area in Australia as an example, simulations were performed with the proposed Attention-LSTM model and other models. Results show that the proposed model outperforms other models in terms of prediction accuracy and algorithm robustness.

KEY WORDS: load forecasting; electricity market; maximum information coefficient; LSTM; Attention mechanism

摘要: 电力市场环境下, 精准的短期负荷预测可以保障电网安全稳定运行, 但电价的实时波动增加了负荷变化的复杂性, 加大了预测难度。针对这一问题, 采用最大信息系数法分析电价及历史负荷与当前时刻负荷的相关性, 为预测模型输入特征的确定提供依据。在此基础上, 提出了基于 Attention-LSTM (attention long short-term memory, Attention-LSTM) 网络的短期负荷预测模型。该模型充分利用负荷的时序特性, 并采用 Attention 机制突出对负荷预测起到关键作用的输入特征。以澳大利亚某地区真实数据为算例, 分别应用 Attention-LSTM 模型与其他模型进行仿真实验。结果表明, 所提方法在预测精度和算法鲁棒性方面均优于其他模型。

关键词: 负荷预测; 电力市场; 最大信息系数; LSTM;

Attention 机制

DOI: 10.13335/j.1000-3673.pst.2018.1554

0 引言

电力市场改革是我国发展的必然趋势与要求, 其中电价市场化则是重中之重。目前, 电价虽未实现实时交易, 但借助国外成熟市场的经验和数据, 对实时电价下的短期负荷预测研究具有重要意义。在完全自由的电力市场运营模式下, 实时变化的电价是影响负荷波动的重要因素, 它增加了负荷预测的复杂程度, 因此, 如何提高负荷预测精度已成为亟待解决的问题。

传统的方法有时间序列法、多元线性法等, 文献[1]采用加权最小二乘估计的自回归滑动平均模型来进行负荷预测, 文献[2]根据人口和全社会用电量等历史数据建立了多元线性回归模型。这些方法多是针对线性关系模型, 预测误差较大。近年来, 机器学习算法能够深度挖掘历史数据中的规律信息, 预测效果较为理想, 被广泛应用于负荷预测。文献[3]通过寻找预测日的相似日, 以预测时刻最大相似日的前几时刻作为输入变量建立横向预测模型, 以预测时刻的不同相似日中的相同时刻建立纵向负荷预测模型, 再将两种模型利用粒子群优化算法进行组合得到较高的预测精度。文献[4]通过分析温度、湿度、气压等 8 个气象因素对负荷的影响, 采用 SVM(support vector machine)、Elman(Elman neural network)和 BP(back propagation)神经网络进行组合预测。

上述文献没有考虑电价对负荷的影响, 不利于电力市场下的负荷预测。文献[5]考虑了实时电价对负荷的影响, 提出了支持向量分位数回归与核密度

估计相结合的负荷预测模型,有效地提高了预测精度。文献[6]同时考虑了电价与历史负荷因素,采用灰色系统和神经网络相结合的方法建立负荷预测模型,有效地提高了预测精度。但这些方法在处理大数据量负荷预测方面,存在收敛速度慢、预测精度低的缺点。

最近几年,深度学习算法发展迅速,孔祥玉等人^[7]将深度信念网络应用于负荷预测中,取得了理想的效果。通过分析历史数据发现,负荷在短时间尺度下具有较为明显的周期性规律,在预测时应该考虑其时序相关性。而深度学习模型中的长短期记忆^[8]模型恰好具有记忆能力,可以有效地学习历史序列数据中的规律信息,在语言建模、语音识别、图片描述等方面都取得了成功。文献[9]基于 LSTM 网络建立了风电功率预测模型,提高了风电功率超短期预测精度。文献[10]利用负荷数据之间的相关性,应用 LSTM 模型进行负荷预测,但模型仅仅将历史负荷作为输入,忽略了其他影响负荷的因素。

目前,采用 LSTM 方法预测负荷时关注的重点都是输入序列的选择,未考虑到输入序列对于负荷的影响程度,这必然会降低预测的精度。另一方面,基于注意力机制(Attention)的神经网络近几年在自然语言处理领域取得了很好的应用效果,如机器翻译、句法分析和自动文摘等。该机制通过为神经网络隐藏层单元分配不同概率权重,使得隐藏层能够关注更为关键的信息。因此,本文设计了一个基于 Attention-LSTM 的短期负荷预测模型。首先,采用最大信息系数分析不同因素对负荷的影响,结果表明除了传统的气象因素外,电价及历史负荷也与当前负荷有着较强的相关性。接着,以温度、湿度、电价以及历史负荷等作为输入特征,在 LSTM 模型的基础上引入 Attention 机制重点突出对预测结果具有关键影响的数据序列,建立多步长、多变量的短期负荷预测模型。最后,通过澳大利亚某地区 5 年真实数据进行仿真计算,并与基于 LSTM、RNN (recurrent neural network)以及 SVM 的预测模型进行比较,结果表明本文方法具有更高的预测精度。

1 影响负荷的因素分析

电力市场化运营模式下,除了气象、地域、行业等因素会对负荷水平产生影响外,实时波动的电价也不可忽视。电价的变化会改变用户的用电行为,形成与固定电价下不同的负荷曲线。此外,电力负荷具有一定的日周期特性和趋势性,相邻时刻或不同日期相同时刻的负荷对预测当前时刻负荷

值具有很高的参考价值。

因此,本文重点分析电价及历史负荷对当前时刻负荷的影响。由于这些因素与负荷之间的关系是非线性的,综合考虑计算复杂度、鲁棒性等指标,采用最大信息系数^[11](maximal information coefficient, MIC)分析影响变量间的相关性。

1.1 最大信息系数

MIC 在互信息(mutual information, MI)的基础上发展而来,具有公平性和广泛性^[12]。互信息可以衡量变量之间的非线性依赖程度,两个变量之间互信息越大,相关性越强。MIC 克服了互信息对连续变量计算不便的缺点,更能体现属性之间的关联程度^[13]。

对于一个二元数据集 $D \in \mathbb{R}^2$, 将 D 划分为 x 列 y 行的网格。对于划分的网格 G , 计算 G 中的每个单元的概率, 得到二元数据集 D 在网格 G 上的概率分布 $D|_G$ 。求得其最大互信息 $\max I(D|_G)$, 将其保存为 $I^*[D(x, y)]$, 如下所示:

$$I^*[D(x, y)] = \max I(D|_G) \quad (1)$$

将其得到的互信息标准化, 并求出最大互信息系数如下:

$$M(D)_{x,y} = \frac{I^*[D(x,y)]}{\lg \min\{x,y\}} \quad (2)$$

$$\text{s.t. } xy < B(n)$$

$$F(D)_{\text{MIC}} = \max_{xy < B(n)} \{M(D)_{x,y}\} \quad (3)$$

式中: n 为采样样本大小; $B(n)$ 是关于采样样本大小的函数, 表示网格 G 划分方格总数 xy 的约束, 需小于 $B(n)$, 一般 $B(n) = n^{0.6}$ 。从本质上来讲, MIC 是一种归一化的最大互信息, 取值区间为 $[0, 1]$ 。两个变量之间的 MIC 值越大, 则其相关性越强; MIC 值越小, 相关性越弱。

1.2 电价与负荷的相关性分析

本文选取澳大利亚新南威尔士州 2006 年到 2010 年的数据^[14], 进行电价与负荷相关性分析。

设 $L_i^* = \{l_i(1), l_i(2), \dots, l_i(t), \dots, l_i(T)\}$ 表示第 i 天的负荷序列, 其中 $l_i(t)$ 表示第 i 天第 t 个采样间隔的负荷值, T 是 1 天中负荷序列的个数。 $P_i^* = \{p_i(1), p_i(2), p_i(3), \dots, p_i(T)\}$ 表示第 i 天的 T 个采样间隔的电价。本文数据采样间隔为 0.5h, 即 T 取值为 48。计算每一日 P_i^* 与 L_i^* 的相关性, 统计结果显示 $\text{MIC} > 0.3$ 的天数, 共计 888 天, 约占 48.6%, 其中 $\text{MIC} > 0.5$ 共有 501 天, 占 27.4%。

图 1 是该地区 2006 年的 1 月份的某一工作日的电价与负荷曲线。可以看出, 电价与负荷的走势




图 1 电价与负荷曲线
Fig. 1 Curve of electricity price and load

基本一致。当负荷较低时，电价也较低，当负荷逐渐增大时，电价也随之增长。当负荷达到峰值时，电价也达到了峰值，用户通过查看实时电价，减少用电，负荷值减小，起到削峰的作用；当负荷出现低谷时，电价也较低，鼓励用户增加用电，达到填谷的目的。因此在电力市场下，电价的变化一定程度影响着负荷的趋势。

1.3 历史负荷与当前负荷的相关性分析

由于负荷具有日周期特性，且相邻时刻波动较小。因此，以当前时刻负荷为参照，分析过去时刻负荷对当前负荷的影响，可以挖掘不同负荷序列之间的时序性。

定义两个时刻负荷变化率的公式为

$$d = \frac{|l(t+1) - l(t)|}{l(t)} \times 100\% \quad (4)$$

分别计算 $l_i(t-1)$ 、 $l_i(t-2)$ 与 $l_i(t)$ 的负荷变化率，统计结果表明变化率在 5% 范围内的样本占比分别为 93%、67%。可见相邻时刻的负荷波动较小，对预测当前时刻负荷的参考价值较大。利用同样方法，统计 $l_{i-1}(t)$ 、 $l_{i-1}(t-1)$ 与 $l_i(t)$ 的负荷变化率在 5% 范围内的数据，占比分别为 64%、58%。虽然占比有所降低，但仍处于较高水平，对预测当前时刻负荷也具有参考价值。

设 $L_i(t) = \{l_{i-1}(t+1), l_{i-1}(t+2), \dots, l_{i-1}(T), l_i(1), \dots, l_i(t)\}$ 表示一个负荷序列，该序列是以 $l_i(t)$ 为最后 1 个负荷项，向第 $i-1$ 天方向扩展的长度为 T 的负荷序列，见图 2。其中 t 的取值为 1 至 T ，当 $t=T$ 时， $L_i(T) = \{l_i(1), l_i(2), \dots, l_i(T)\} = L_i^*$ ，就是第 i 天的全部负荷序列。同理可得 $L_i(t-1) = \{l_{i-1}(t), l_{i-1}(t+1), l_{i-1}(t+2), \dots, l_{i-1}(T), l_i(1), l_i(2), \dots, l_i(t-1)\}$ ，也是一个长度为 T 的负荷序列，与 $L_i(t)$ 中数据项的关系见图 2。

分别计算 $L_i(t)$ 与 $L_i(t-1)$ 、 $L_i(t-2)$ 、 $L_{i-1}(t)$ 、 $L_{i-1}(t-1)$ 之间的相关性，结果如表 1 所示。其中，




图 2 $L_i(t)$ 、 $L_i(t-1)$ 变量范围表示
Fig. 2 Variable range representation of $L_i(t)$ and $L_i(t-1)$

$L_i(t-1)$ 与 $L_i(t)$ 的相关性最大，MIC 值为 0.96； $L_i(t-2)$ 与 $L_i(t)$ 的相关性次之为 0.85，其次是 $L_{i-1}(t)$ 、 $L_{i-1}(t-1)$ ，MIC 值分别为 0.61、0.6。这与负荷变化率结果一致，完全符合随时间推移其相关性逐渐减弱的变化规律。

表 1 历史负荷与当前负荷的相关性 Tab. 1 Correlation between historical load and current load			
$L_i(t-1)$	$L_i(t-2)$	$L_{i-1}(t)$	$L_{i-1}(t-1)$
0.96	0.85	0.61	0.60

2 基于 Attention-LSTM 的负荷预测模型

2.1 LSTM 网络结构

循环神经网络，在实际应用中存在梯度消失和梯度爆炸问题^[15]。Hochreiter 等^[16]提出了一种改进的 RNN，LSTM 神经网络，可以解决 RNN 无法处理长距离的依赖问题，充分利用历史信息，在时序数据分析中具有更强的适应性。LSTM 的单元结构如图 3 所示。




图 3 LSTM 单元结构
Fig. 3 LSTM unit structure

图 3 中： x_t 和 h_t 分别表示 t 时刻的输入向量和隐含层状态值。记忆单元是神经元状态的记忆，用来记录当前时刻状态。输入门(input gate)、输出门(output gate)用来读取、输出和修正参数。遗忘门(forget gate)用来将上一时刻的单元状态选择性遗忘修正参数。计算公式如下：

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (5)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (6)$$

$$g_t = \tanh(W_g[h_{t-1}, x_t] + b_g) \quad (7)$$

$$C_t = f_i C_{t-1} + i_t g_t \quad (8)$$

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (9)$$

$$h_t = o_t \tanh C_t \quad (10)$$

式中： f 、 i 、 g 、 C 、 o 分别代表遗忘门、输入门、备选的用来更新的细胞状态、更新后的细胞状态和输出门； W 和 b 分别为对应的权重系数矩阵和偏置项； σ 和 $\tanh$ 分别表示 sigmoid 激活函数和双曲正切激活函数。

2.2 Attention 机制

Attention 机制是一种模拟人脑注意力的模型，借鉴了人脑在某个特定时刻对事物的注意力会集中到特定的地方，而减少甚至是忽略对其他部分的注意力^[17]。Attention 通过对模型的输入特征赋予不同的权重，突出更关键的影响因素，帮助模型做出更加准确的判断，而且不会增加模型的计算和存储开销，因此将 Attention 机制引入 LSTM 模型中，来有效突出影响负荷的因素，从而改善预测效果。Attention 结构如图 4 所示^[18]。




图 4 Attention 单元结构

Fig. 4 Attention unit structure

图 4 中 $x_1, x_2, \dots, x_k$ 表示输入序列； $h_1, h_2, \dots, h_k$ 表示对应于输入序列的隐藏层的状态值； α_{ki} 为历史输入的隐藏层状态对当前输入的注意力权重； h_k 表示最终输出的最后节点的隐藏层状态值。Attention 机制的计算公式如下：

$$\alpha_{ki} = \frac{\exp(s_{ki})}{\sum_{j=1}^{T_x} \exp(s_{kj})} \quad (11)$$

$$s_{ki} = v \tanh(W h_k + U h_i + b) \quad (12)$$

$$C = \sum_{i=1}^{T_x} \alpha_{ki} h_i \quad (13)$$

最后的特征向量 h_k 即最后节点的隐藏向量：

$$h_k' = H(C, h_k, x_k) \quad (14)$$

2.3 Attention-LSTM 模型

Attention-LSTM 模型包括输入向量、两个 LSTM 隐藏层、Attention 层、全连接层以及输出的预测值。输入向量从输入层开始，经过两层 LSTM 隐藏层，输出处理后的向量，作为 Attention 层的输

入，在 Attention 层中，首先会依据当前层输入向量计算出权重向量，然后将权重向量和当前层输入向量合并，得到新的向量，输入到全连接层中，最后计算出预测值。Attention-LSTM 模型见图 5。




图 5 Attention-LSTM 模型

Fig. 5 Attention-LSTM model

在输入层中，经过上文的 MIC 相关性分析，本文选取 7 个因子作为输入特征，用 $U_i(t)$ 表示， $U_i(t)=[c_i(t), h_i(t), p_i(t), l_i(t-1), l_i(t-2), l_{i-1}(t), l_{i-1}(t-1)]$ ，其中 $c_i(t)$ 表示预测点时刻的预报温度， $h_i(t)$ 表示预测点时刻的预报湿度， $p_i(t)$ 表示预测点时刻的预报电价， $l_i(t-1)$ 、 $l_i(t-2)$ 、 $l_{i-1}(t)$ 、 $l_{i-1}(t-1)$ 分别表示预测点前一时刻负荷值、预测点前两时刻负荷值、预测点前一天同时刻负荷值、预测点前一天前一时刻负荷值。

LSTM 层的作用是为了选择记住重要的信息，遗忘不重要的信息。原则上该层层数越多，模型的非线性拟合能力越强，学习效果越好。但是由于训练需要消耗大量时间，所以一般会选择效果较好且用时较少的方案，本实验设置两层 LSTM 能用较少的时间得到很好的效果。按照以往经验来看，神经元的数目一般是 2 的次方数，且第 1 层的神经元数量不能太少，否则无法学习到规律。因此第 1 层 LSTM 设置神经元个数为 128。第 2 层 LSTM 设置神经元个数为 64，这是为了让数据流的体量缩小，减少冗余数据的干扰，同时也为了在进入全连接层之前压缩数据，让全连接层的参数减少。由于全连接层的参数会随着输入数据的增加而成倍递增，所以适当压缩数据是很有必要的。

Attention 层的作用是将模型学习到的特征权重赋予下一个时间步长中的输入向量，突出关键特征对预测负荷的影响。最终数据经过全连接层，然后得到最终输出层为预测时刻的负荷值。本文 LSTM 步长的设置为 10。

3 算例分析

本文选取 2006 年至 2008 年作为训练数据集，2009 和 2010 年作为测试数据集。首先对数据采用归一化处理，将数据映射到 $[-1, 1]$ 区间上。公式如下：

$$X^* = \frac{x - (x_{\max} + x_{\min}) / 2}{(x_{\max} - x_{\min}) / 2} \quad (15)$$

式中 $x_{\max}$ 、 $x_{\min}$ 分别为变量的极大值与极小值。

3.1 误差指标

误差指标采用平均绝对百分比误差(mean absolute percentage error, MAPE)和均方根误差(root mean square error, RMSE), 公式如下:

$$e_{\text{MAPE}} = \frac{1}{n} \sum_{i=1}^n \frac{|l_i - l'_i|}{l_i} \times 100\% \quad (16)$$

$$e_{\text{RMSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (l_i - l'_i)^2} \quad (17)$$

式中: n 为预测点个数; l_i 表示第 i 点的实际负荷值; l'_i 表示第 i 点的预测负荷值。

通过计算 e_{MAPE} 的标准差来评价模型预测误差的波动程度, 检验模型的鲁棒性和稳定性:

$$\sigma_{\text{MAPE}} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (m_i - \bar{m})^2} \quad (18)$$

式中: n 为预测天数; m_i 为第 i 天的平均绝对百分比误差; $\bar{m}$ 为 n 天的绝对百分比误差平均值。

3.2 输入特征对模型的影响

为了说明输入特征对负荷预测模型的影响, 分别采用不同变量组合作为模型输入。ML 表示将历史负荷 $l_i(t-1)$ 、 $l_i(t-2)$ 、 $l_{i-1}(t)$ 和 $l_{i-1}(t-1)$ 作为模型输入, CH 表示将温度 $c_i(t)$ 和湿度 $h_i(t)$ 作为模型输入, CHP 表示将 $c_i(t)$ 、 $h_i(t)$ 和电价 $p_i(t)$ 作为模型输入, CHPL 表示将 $c_i(t)$ 、 $h_i(t)$ 、 $p_i(t)$ 、 $l_i(t-1)$ 、 $l_i(t-2)$ 、 $l_{i-1}(t)$ 和 $l_{i-1}(t-1)$ 作为模型输入。通过实验比较不同输入特征的负荷预测效果, 结果如表 2 所示。当仅用温度、湿度作为输入时, 可挖掘的信息量较少, 预测精度最低; 在此基础上增加电价因素后, 预测精度有所提高, 说明电价能够正向影响负荷; 当加入历史负荷时, 精度提升幅度较大, 进一步验证了负荷日周期性的重要程度; 当所有数据都作为输入特征时, 预测模型能够充分学习数据中的有效信息和隐含规律, 预测效果最佳, 年平均 e_{MAPE} 值达到 0.572%, e_{RMSE} 也大幅度降低。

表 2 不同输入特征的模型的预测误差
Tab. 2 Prediction errors of the model with different input features

模型	2009 年		2010 年	
	$e_{\text{MAPE}}/\%$	$e_{\text{RMSE}}/\text{MW}$	$e_{\text{MAPE}}/\%$	$e_{\text{RMSE}}/\text{MW}$
ML	0.592	69.558	0.639	71.523
CH	7.261	832.250	7.663	860.300
CHP	5.454	658.971	5.268	624.757
CHML	0.587	70.539	0.625	72.238
CHPML	0.567	67.570	0.578	67.078

3.3 不同模型的预测效果对比

本文方法分别与基于 LSTM、RNN、SVR 算法的预测模型进行实验对比, 其中, LSTM 与 RNN 均采用两层隐藏层, 每层神经元个数分别设置为 128、64, 激活函数选取 tanh 函数, 迭代次数为 150 次, LSTM 步长设置为 10, RNN 步长设置为 1, SVM 采用径向基函数(radical basis function, RBF)作为核函数。每个模型每次都是输出一个时刻的负荷预测值, 1 天的预测值指的是循环预测 1 天中 48 个时刻的负荷值。

以 2006—2008 年数据作为训练集, 分别应用 4 种预测模型对 2009 和 2010 年数据进行预测。表 3 列出了 2009 年和 2010 年各个预测模型的年均 e_{MAPE} 、 e_{RMSE} 和 σ_{MAPE} 值。Attention-LSTM 模型的 e_{MAPE} 均值为 0.557%, 相对于 LSTM、RNN、SVM 模型分别提高了 0.065%、0.217%、1.035%, Attention-LSTM 模型的 e_{RMSE} 均值为 65.086 MW, 相对于相比其他模型也有明显降低。从预测结果来看, LSTM 模型能够有效地利用历史序列信息, 在时序预测问题中效果非常理想。而将 Attention 机制引入 LSTM 中, 可以突出关键序列的作用, 进一步提升了预测效果。

表 3 不同模型预测的年度误差对比
Tab. 3 Comparison of prediction error between different models for two years

模型	2009 年			2010 年		
	$e_{\text{MAPE}}/\%$	$e_{\text{RMSE}}/\text{MW}$	σ_{MAPE}	$e_{\text{MAPE}}/\%$	$e_{\text{RMSE}}/\text{MW}$	σ_{MAPE}
Attention-LSTM	0.554	65.353	0.029	0.560	64.818	0.029
LSTM	0.596	68.281	0.044	0.647	70.964	0.049
RNN	0.735	85.167	0.079	0.811	92.754	0.033
SVM	1.610	163.670	0.064	1.575	158.313	0.089

另一方面, 从 σ_{MAPE} 指标来看, Attention-LSTM 模型的平均 σ_{MAPE} 最小, 说明本文模型具有较好的普适性, 可以适用不同季节的负荷变化规律, 模型的鲁棒性和稳定性更好, 更适合于实际应用。此外, 对各个模型的计算速度进行了对比, Attention-LSTM 模型的平均时间为 11.92 s, SVM、RNN、LSTM 模型的平均时间分别为 12.18、11.3、12.91 s。可以看出本文所提模型在计算速度上较 SVM、LSTM 模型具有优势。

为了进一步分析模型性能, 统计并计算每个月的 e_{MAPE} 、 e_{RMSE} 值, 表 4 列出了 2010 年的统计结果。可以看出 Attention-LSTM 模型在 2010 年 e_{MAPE} 指标最小为 0.506%, 最大为 0.674%, 所有月份的预测误差均小于 RNN、SVM 模型, 除了 7 月份的预测误差略大于 LSTM 模型以外, 其余月份均优于 LSTM 模型。需要说明, 由于 1 月份和 12 月份受澳

表 4 2010 年每月的预测误差对比
Tab. 4 Comparison of monthly forecast error in 2010

模型	1 月		2 月		3 月		4 月		5 月		6 月	
	$e_{MAPE}/\%$	e_{RMSE}/MW	$e_{MAPE}/\%$	e_{RMSE}/MW	$e_{MAPE}/\%$	e_{RMSE}/MW	$e_{MAPE}/\%$	e_{RMSE}/MW	$e_{MAPE}/\%$	e_{RMSE}/MW	$e_{MAPE}/\%$	e_{RMSE}/MW
Attention-LSTM	0.64	77.618	0.537	66.65	0.534	61.488	0.592	62.168	0.509	60.76	0.524	65.986
LSTM	0.751	83.746	0.656	74.872	0.668	70.211	0.715	72.126	0.576	66.274	0.539	66.57
RNN	0.88	108.754	0.79	100.281	0.732	80.934	0.918	92.513	0.769	88.626	0.8	103.475
SVR	1.544	164.311	1.443	156.041	1.346	136.011	1.622	151.161	1.59	159.326	1.675	180.049

模型	7 月		8 月		9 月		10 月		11 月		12 月	
	$e_{MAPE}/\%$	e_{RMSE}/MW	$e_{MAPE}/\%$	e_{RMSE}/MW	$e_{MAPE}/\%$	e_{RMSE}/MW	$e_{MAPE}/\%$	e_{RMSE}/MW	$e_{MAPE}/\%$	e_{RMSE}/MW	$e_{MAPE}/\%$	e_{RMSE}/MW
Attention-LSTM	0.525	66.686	0.506	61.132	0.523	58.145	0.579	63.256	0.577	61.274	0.674	72.657
LSTM	0.498	63.618	0.53	63.705	0.597	64.888	0.7	71.243	0.715	71.752	0.82	82.479
RNN	0.819	106.293	0.755	93.224	0.755	82.091	0.817	84.011	0.79	81.103	0.91	91.749
SVR	1.623	176.153	1.695	177.221	1.603	155.289	1.601	149.011	1.515	143.461	1.63	151.729

大利亚季节特性因素影响，负荷波动较大，导致每个预测模型的预测误差都相对较大。

图 6 为 2010 年 12 月某两天的负荷预测曲线，表 5 为其中 1 天部分时刻的负荷预测结果。从图中可以看出在负荷曲线的波峰和波谷区域，LSTM、RNN、SVM 模型的预测数值都出现了一定程度的偏差。而 Attention-LSTM 模型同时结合了电价与历史负荷的规律，预测结果与真实曲线拟合程度最好，预测精度最为理想。从表 5 中也可以看出，Attention-LSTM 模型的平均 e_{MAPE} 为 0.576%，误差小于其他 3 个模型，预测效果最好。




图 6 负荷预测曲线

Fig. 6 Curve of load forecasting

表 5 2010 年 12 月某日部分时刻的负荷预测结果
Tab. 5 Load forecasting results for some time on a certain day in December 2010

时刻	实际值/MW	Attention-LSTM 模型		LSTM 模型		RNN 模型		SVM 模型	
		预测值/MW	$e_{MAPE}/\%$	预测值/MW	$e_{MAPE}/\%$	预测值/MW	$e_{MAPE}/\%$	预测值/MW	$e_{MAPE}/\%$
1:00	7017.83	7024.42	0.094	7080.52	0.893	7108.86	1.297	7133.36	1.646
3:00	6137.21	6152.46	0.205	6169.48	0.525	6175.10	0.468	6443.65	4.626
5:00	6288.74	6382.83	1.496	6411.63	1.954	6455.52	2.652	6585.92	4.725
7:00	7470.71	7533.02	0.834	7549.77	1.058	7537.54	0.894	7453.82	0.226
9:00	8755.74	8778.49	0.259	8814.74	0.673	8776.95	0.242	8786.21	0.348
11:00	9209.37	9161.91	0.515	9171.49	0.411	9199.56	0.523	9260.43	0.554
13:00	9513.32	9477.39	0.378	9511.84	0.016	9533.09	0.208	9598.87	0.899
15:00	9696.81	9734.43	0.388	9710.22	0.138	9698.54	0.018	9770.12	0.756
17:00	9799.58	9909.61	1.122	9874.26	0.762	9810.89	0.115	9853.11	0.546
19:00	9147.95	9168.39	0.223	9111.80	0.395	9088.58	0.649	9223.37	0.824
21:00	8629.31	8700.34	0.823	8697.91	0.795	8725.84	1.119	8868.14	2.767
23:00	8094.35	8141.33	0.580	8135.84	0.513	8159.52	0.805	8251.73	1.944
$e_{MAPE}/\%$		0.576		0.678		0.749		1.655	

4 结论

针对电力市场条件下影响负荷的因素众多且较为复杂的问题，提出了一种融合电价与历史负荷数据的短期负荷预测模型，并通过实际算例进行了验证。本文的主要结论为：

1) 采用 MIC 方法确定电价与历史负荷对当前时刻负荷存在较强的相关性，负荷预测时必须作为重要因素予以考虑。

2) 利用负荷的时序特性，结合气象因素、电价和历史负荷序列，建立了一种基于 Attention-LSTM 网络的短期负荷预测模型，并利用 Attention 机制对输入特征赋予不同的权值，以突出对负荷预测起到关键作用的特征。

3) 本文方法充分挖掘电价与历史负荷中规律信息，具有较好的鲁棒性及较高的预测精度。

参考文献

[1] 叶瑰昀, 罗耀华, 刘勇, 等. 基于 ARMA 模型的电力负荷预测方

- 法研究[J]. 信息技术, 2002(6): 74-76.
- Ye Guiyun, Luo Yaohua, Liu Yong, et al. Research on method of power system load forecasting based on ARMA model[J]. Information Technology, 2002(6): 74-76(in Chinese).
- [2] 彭鹏, 彭佳红. 基于多元线性回归模型的电力负荷预测研究[J]. 中国安全生产科学技术, 2011, 7(9): 158-161.
- Peng Peng, Peng Jiahong. Power load based on multiple linear regression model prediction[J]. Journal of Safety Science and Technology, 2011, 7(9): 158-161(in Chinese).
- [3] 陈鸿琳, 李欣然, 冷华, 等. 运用 PSO 和 GRNN 的短期负荷二维组合预测[J]. 电力系统及其自动化学报, 2018, 30(2): 86-89.
- Chen Honglin, Li Xinran, Leng Hua, et al. Bidirectional combined short-term load forecasting by using PSO and GRNN[J]. Proceedings of the CSU-EPSA, 2018, 30(2): 86-89(in Chinese).
- [4] Xi Chen, Jing Qu, Zhao Yangdong. An improved load forecast model using factor analysis: an Australian case study[C] //Proceedings of the 2017 IEEE International Conference on Information and Automation(ICIA). Macau SAR, China: IEEE, 2017: 903-908.
- [5] 何耀耀, 刘瑞, 撒奥洋. 基于实时电价与支持向量分位数回归的短期电力负荷概率密度预测方法[J]. 中国电机工程学报, 2017, 37(3): 768-774.
- He Yaoyao, Liu Rui, Han Aoyang. Short-term power load probability density forecasting method based on real time price and support vector quantile regression[J]. Proceedings of the CSEE, 2017, 37(3): 768-774(in Chinese).
- [6] 葛少云, 贾鸥莎, 刘洪. 基于遗传灰色神经网络模型的实时电价条件下短期电力负荷预测[J]. 电网技术, 2012, 36(1): 224-229.
- Ge Shaoyun, Jia Ousha, Liu Hong. A gray neural network model improved by genetic algorithm for short-term load forecasting in price-sensitive environment[J]. Power System Technology, 2012, 36(1): 224-229(in Chinese).
- [7] 孔祥玉, 郑锋, 鄂志君, 等. 基于深度信念网络的短期负荷预测方法[J]. 电力系统自动化, 2018, 42(5): 133-138.
- Kong Xiangyu, Zheng Feng, E Zhijun, et al. Short term load forecasting method based on deep belief network[J]. Automation of Electric Power Systems, 2018, 42(5): 133-138(in Chinese).
- [8] Graves A. Supervised sequence labeling with recurrent neural networks[M]. Berlin: Springer, 2012, 32-39.
- [9] 朱乔木, 李弘毅, 王子琪, 等. 基于长短期记忆网络的风电场发电功率超短期预测[J]. 电网技术, 2017, 41(12): 3797-3802.
- Zhu Qiaomu, Li Hongyi, Wang Ziqi, et al. Short-term wind power forecasting based on LSTM[J]. Power System Technology, 2017, 41(12): 3797-3802(in Chinese).
- [10] 张宇航, 邱才明, 贺兴. 一种基于 LSTM 神经网络的短期用电负荷预测方法[J]. 电力信息与通信技术, 2017, 15(9): 19-24.
- Zhang Yuhang, Qiu Caiming, He Xing. A short-term load forecasting method based on LSTM neural network[J]. Electric Power Information and Communication Technology, 2017, 15(9): 19-24(in Chinese).
- [11] Reshef D N, Reshef Y A, Finucane H K, et al. Detecting novel associations in large data sets[J]. Science, 2011, 334(6062): 1518-1524.
- [12] Justin B K, Gurinder S A. Equitability, mutual information, and the maximal information coefficient[J]. PNAS, 2014, 111(9): 3354-3359.
- [13] 王中伟, 宋宏, 李帅, 等. 基于对数变换和最大信息系数 PCA 的过程监测[J]. 科学技术与工程, 2017, 17(16): 259-265.
- Wang Zhongwei, Song Hong, Li Shuai, et al. Process monitoring based on logarithmic transformation and maximum information coefficient PCA[J]. Science Technology and Engineering, 2017, 17(16): 259-265(in Chinese).
- [14] Australian Energy Market Operator. AEMO's first national gas forecasting report[R/OL]. [2014-11-17]. <http://www.aemo.com.au>.
- [15] Kolen J, Kremer S, Frasconi P, et al. Gradient flow in recurrent nets: the difficulty of learning long-term dependencies[M]. Wiley-IEEE Press, New York, 2001: 237-243.
- [16] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [17] 朱星嘉, 李红莲, 吕学强, 等. 一种改进的 Attention-Based LSTM 特征选择模型[J]. 北京信息科技大学学报(自然科学版), 2018, 33(2): 54-59.
- Zhu Xingjia, Li Honglian, Lu Xueqiang, et al. An improved Attention-based LSTM feature selection model[J]. Journal of Beijing Information Science & Technology University, 2018, 33(2): 54-59(in Chinese).
- [18] 张冲. 基于 Attention-based LSTM 模型的文本分类技术的研究[D]. 南京: 南京大学, 2016.



彭文

收稿日期: 2018-07-09。

作者简介:

彭文(1980), 男, 讲师, 研究方向为负荷预测与电网规划, E-mail: pengwen@ncepu.edu.cn;
王金睿(1994), 女, 硕士研究生, 通信作者, 研究方向为负荷预测, E-mail: 804425240@qq.com;
尹山青(1994), 男, 硕士研究生, 研究方向为负荷预测, E-mail: 1208300547@qq.com。

(责任编辑 王金芝)